Interpretabilidad

Recuerada que existen modelos de caja blanca, como los árboles de decisión, que no tienen un problema de interpretabilidad. Sin embargo, este hecho es excepcional: la mayoría de modelos, más aún dentro del campo del *deep learning*, son de caja negra. Es decir: se conoce la información de entrada y el resultado, pero no existe una forma trivial de enlazar ambos datos.

La **intepretabilidad** es una rama dentro del *machine learning* que tiene como objetivo explicar las decisiones tomadas por estos modelos. Es un campo general dentro de la Inteligencia Artificial (no está directamente vinculada con el *deep learning*), así que tiene estrategias para explicar modelos de caja negra clásicos y otras para explicar modelos de caja negra *deep*.

Durante este cuadernillo daremos cobertura a ambos contextos: clásico y *deep*.

Interpretabilidad de modelos *deep* (técnica Grad-CAM)

Aprovechando que el tema actual trata los modelos *deep*, hablaremos primero de la interpretabilidad de este tipo de modelos.

La técnica principal, denominada Grad-CAM y definida en este trabajo, es introducir una capa extra en la parte final de los modelos (la que determina el resultado --etiqueta, imagen...--) que sea capaz de explicar los cambios en el gradiente que allí se producen.

Veamos un ejemplo. Lo primero que vamos a hacer es recuperar el modelo de clasificación de imágenes que creamos en el cuadernillo `502`.

Instalamos e importamos las librerías necesarias.

```
!pip install fastai -Uqqq
!pip install fastprogress==1.0.3 # 08/02/2026: esta librería se ha actualizado. Hasta que FASTAI se actualice, tenemos que usar la versión
```

```
Collecting fastprogress==1.0.3
  Downloading fastprogress-1.0.3-py3-none-any.whl.metadata (5.6 kB)
Downloading fastprogress-1.0.3-py3-none-any.whl (12 kB)
Collecting fastprogress==1.0.3
  Downloading fastprogress-1.0.3-py3-none-any.whl.metadata (5.6 kB)
Downloading fastprogress-1.0.3-py3-none-any.whl (12 kB)
Installing collected packages: fastprogress
  Attempting uninstall: fastprogress
Installing collected packages: fastprogress
  Attempting uninstall: fastprogress
    Found existing installation: fastprogress 1.1.3
    Uninstalling fastprogress-1.1.3:
      Successfully uninstalled fastprogress-1.1.3
Successfully installed fastprogress-1.0.3
    Found existing installation: fastprogress 1.1.3
    Uninstalling fastprogress-1.1.3:
      Successfully uninstalled fastprogress-1.1.3
Successfully installed fastprogress-1.0.3
```

```
from fastai.vision.all import *

random_seed = 33
```

Recuperamos nuestros datos desde este enlace y los estructuramos.

```
%%capture
!unzip 502\ cat_dog_dataset.zip
```

```
dataset_path = Path("dataset")
test_path = Path(dataset_path/"test")
train_path = Path(dataset_path/"train")
```

Definimos las transformaciones que necesitamos para realizar aumento de datos.

```
from albumentations import *

class TransformPipeline(ItemTransform):
  def __init__(self, train = True):
    if train:
      self.aug = Compose([
        VerticalFlip(p = 0.2),
        GaussNoise(p = 0.2),
        Rotate(p = 0.2),
        Resize(256, 256, p = 1) # esto se aplica siempre
      ])
    else:
      self.aug = Compose([
        Resize(256, 256, p = 1) # en testeo, solo aplico el cambio de tamaño
      ])
```

```
  def encodes(self, x): # este método es muy importante, recibe cada uno de los datos y lo procesa
    if len(x) == 1:
      return x

    image, label = x
    res = self.aug(image = np.array(image)) # nuestro procesamiento es aplicar aumentos a la imagen
    return PILImage.create(res["image"]), label
```

Creamos un `DataBlock` y obtenemos su `DataLoader` asociado.

```
db = DataBlock(
    blocks=(ImageBlock, CategoryBlock),
    get_items = get_image_files,
    splitter = RandomSplitter(valid_pct = 0.2, seed = random_seed),
    get_y = parent_label,
    item_tfms = [TransformPipeline(train = True)]
)

dls = db.dataloaders(train_path)

dls.show_batch()
```

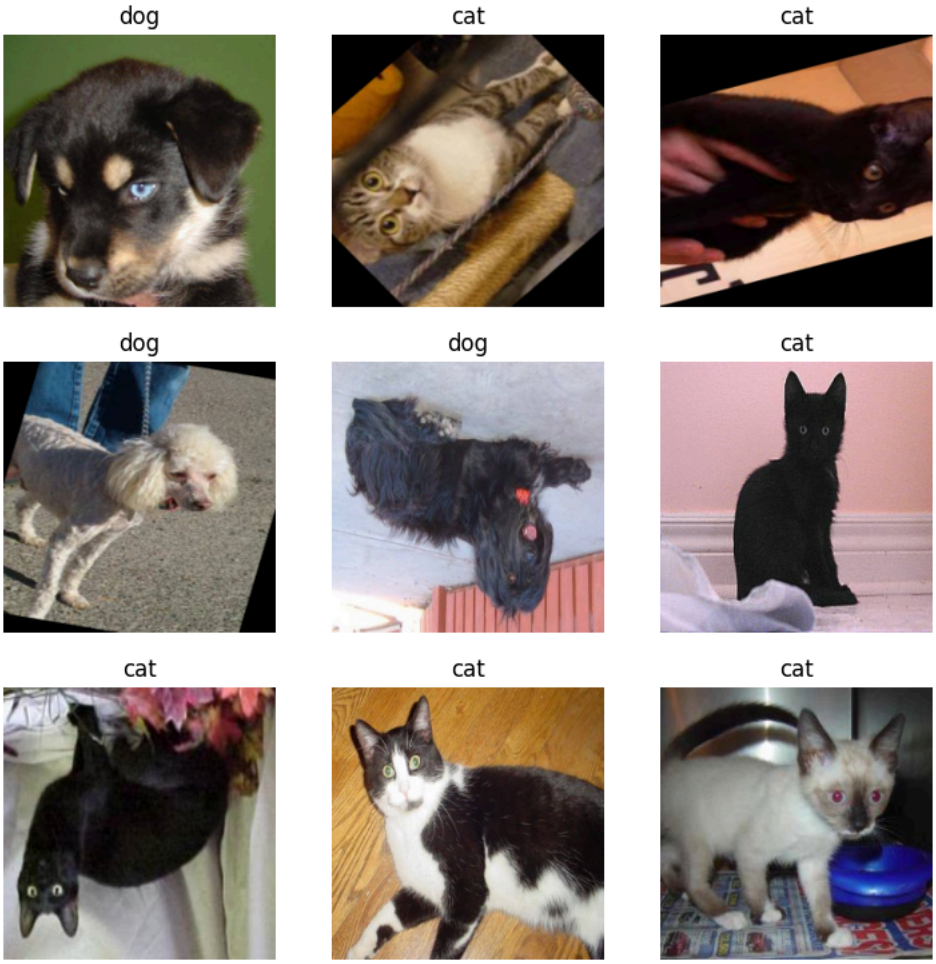

Ahora el `Learner`.

```
learner = vision_learner(dls, resnet50)
```

```
Downloading: "https://download.pytorch.org/models/resnet50-11ad3fa6.pth" to /root/.cache/torch/hub/checkpoints/resnet50-11ad3fa6.pth
100%|██████████| 97.8M/97.8M [00:01<00:00, 54.7MB/s]
```

```
learner.lr_find()
```

```
SuggestedLRs(valley=0.0005754399462603033)
```

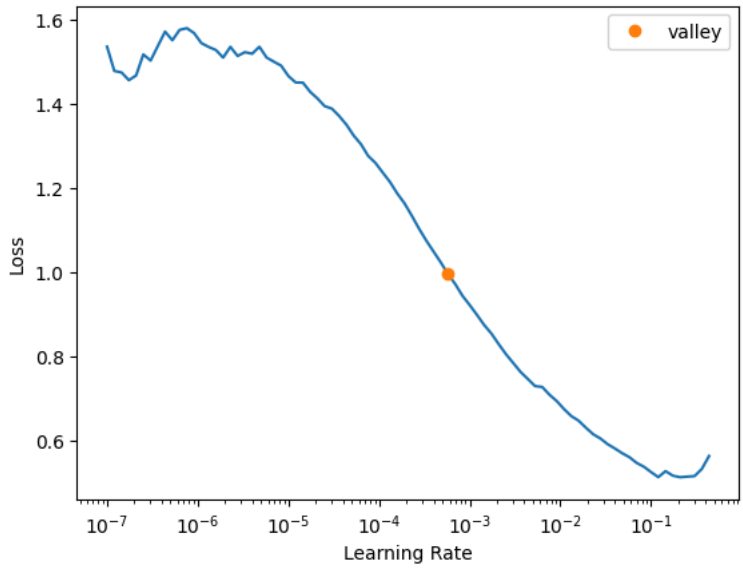

Entrenamos.

```
learner.fine_tune(10, 0.001, 2)
```

epoch	train_loss	valid_loss	time
0	1.336133	0.807962	00:02
1	1.133200	0.211048	00:02

epoch	train_loss	valid_loss	time
0	0.347549	0.183712	00:03
1	0.316869	0.145966	00:02
2	0.307043	0.127591	00:02
3	0.252488	0.170241	00:02
4	0.217117	0.223533	00:02
5	0.205050	0.207772	00:02
6	0.185867	0.190592	00:02
7	0.174461	0.171113	00:02
8	0.159181	0.160037	00:02
9	0.150568	0.155115	00:02

Ahora que el modelo está entrenado, podemos introducir la capa extra de **interpretabilidad**.

Usaremos el mapa de activación de clases (CAM) que utiliza la última capa y los resultados del propio modelo para mostrar un mapa de calor.

En particular, usaremos los gradientes de estas capas. No podemos acceder a ellos directamente, sino que necesitamos utilizar un `hook`. Los `hook` son parecidos a los `CallBacks`. Mientras que estos segundos nos permitían añadir código antes o después de las etapas de creación, entrenamiento y testeo del modelo, los `hook` nos permiten añadir código en las etapas de propagación de los gradientes (*forward* y *backforward*).

```
class Hook():
  def __init__(self, model):
    self.hook = model.register_forward_hook(self.hook_func)

  def hook_func(self, model, input, output):
    self.stored = output.detach().clone()

  def __enter__(self, *args):
    return self

  def __exit__(self, *args):
    self.hook.remove()
```

```
class HookBwd():
  def __init__(self, model):
    self.hook = model.register_backward_hook(self.hook_func)

  def hook_func(self, model, grid_input, grid_output):
    self.stored = grid_output[0].detach().clone()
```

```
  def __enter__(self, *args):
    return self

  def __exit__(self, *args):
    self.hook.remove()
```

Ahora vamos a crear el `DataLoader` de testeo.

```
db_test = DataBlock(
    blocks=(ImageBlock, CategoryBlock),
    get_items = get_image_files,
    splitter = GrandparentSplitter(train_name = "train", valid_name = "test"),
    get_y = parent_label,
    item_tfms = [TransformPipeline(train = False)]
)

dls_test = db.dataloaders(dataset_path)
learner.dls = dls_test
```

Y ahora podemos predecir un ejemplo cualquiera.

```
example = test_path/"cat/cat.4896.jpg"
img = PILImage.create(example)
example_coded = first(dls_test.test_dl([img]))[0]
print(learner.predict(img))
```

```
('cat', tensor(0), tensor([0.8595, 0.1405]))
```

Bien, está bien predicho con una certeza del 98% (al menos el modelo está al 98% seguro de que es un gato).

La pregunta importante ahora es, ***¿por qué el modelo está tan seguro de que es un gato? ¿En qué se está fijando?***.

Aplicando técnicas de **interpretabilidad** sobre el objeto x podremos descubrirlo.

Usando los `hook` que hemos definido antes, vamos a capturar los descriptores de la última capa convolucional y vamos a calcular los gradientes de las activaciones para la clase *gato* (*cat*).

```
with HookBwd(learner.model[0]) as hookg:
  with Hook(learner.model[0]) as hook:
    output = learner.model.eval()(example_coded.cuda())
    act = hook.stored
  output[0, 0].backward()
  grad = hookg.stored
```

```
/usr/local/lib/python3.12/dist-packages/torch/nn/modules/module.py:1866: FutureWarning: Using a non-full backward hook when the forward co
  self._maybe_warn_non_full_backward_hook(args, result, grad_fn)
/usr/local/lib/python3.12/dist-packages/torch/nn/modules/module.py:1866: FutureWarning: Using a non-full backward hook when the forward co
  self._maybe_warn_non_full_backward_hook(args, result, grad_fn)
```

Necesitamos la media de los pesos de los gradientes. Podemos obtenerla de la siguiente forma:

```
w = grad[0].mean(dim = [1, 2], keepdim = True)
cam_map = (w * act[0]).sum(0)
```

Finalmente, creamos un mapa de calor y lo visualizamos.

```
# decodificamos la imagen ejemplo
example_decoded = TensorImage(dls.train.decode((example_coded,))[0][0])

# visualización
_, ax = plt.subplots()
example_decoded.show(ctx = ax)
ax.imshow(
  cam_map.detach().cpu(),
  alpha = 0.6,
  extent = (0, example_coded.shape[2], example_coded.shape[3], 0),
  interpolation='bilinear',
  cmap='magma'
);
```

Como puedes observar, el modelo determina que esa imagen es un gato por los puntos más brillantes:

- Lomo.
- Patas traseras.
- Orejas.

Esta técnica de **interpretabilidad** puede aplicarse a cualquier capa del modelo, aunque la más interesante es la última (que es donde se determina la clase final).

Interpretabilidad de modelos clásicos (técnica `model distillation`)

En los modelos clásicos, una de las formas más comunes de explicar modelos de caja negra es usando modelos de caja blanca.

La idea es sencilla: como existen modelos que, de por sí, son interpretables; podemos utilizar estos modelos para explicar otros que no lo sean. El proceso es el siguiente:

- Se entrena el modelo de **caja negra**.
- Se predicen los resultados.
- Se entrena el modelo de **caja blanca** mimetizando el comportamiento del modelo de **caja negra**, es decir: el resultado esperado para el modelo de **caja blanca** es el resultado predicho por el modelo de **caja negra**.
- Se interpretan los resultados de la predicción del modelo de **caja blanca**.

Esta técnica es interesante porque puede aplicarse a más campos además del de la **interpretabilidad**. Por ejemplo, nos permite crear *pseudoetiquetadores* para realizar tareas de aprendizaje semi-supervisado con modelos *deep*.

Veamos un ejemplo.

Entrenamiento del modelo de caja negra

Los datos

Lo primero que vamos a hacer es entrenar un modelo clásico, tal y como lo hacíamos en el tema 4. Por ejemplo, entrenaremos un `RandomForest` (que, como ya sabes, aunque sea la unión de varios modelos de caja blanca, es de caja negra).

Vamos a recuperar el mismo ejemplo del cuadernillo `309`, que clasificábamos fumadores. Recupera el [conjunto de datos]() que usábamos.

```
%%capture
!unzip playground-series-s3e24.zip
```

```
import pandas as pd
```

```
train_val = pd.read_csv("train.csv")
train_val.head()
```

	id	age	height(cm)	weight(kg)	waist(cm)	eyesight(left)	eyesight(right)	hearing(left)	hearing(right)	systolic	...	HDL	LDL	hemo
0	0	55	165	60	81.0	0.5	0.6	1	1	135	...	40	75	
1	1	70	165	65	89.0	0.6	0.7	2	2	146	...	57	126	
2	2	20	170	75	81.0	0.4	0.5	1	1	118	...	45	93	
3	3	35	180	95	105.0	1.5	1.2	1	1	131	...	38	102	
4	4	30	165	60	80.5	1.5	1.0	1	1	121	...	44	93	

Aunque ahora no vayamos a hacer inferencia, siempre es buena costumbre separar el conjunto de testeo.

```
from sklearn.model_selection import train_test_split

random_seed = 33
```

```
train, val = train_test_split(train_val, test_size=0.15, random_state=random_seed)
```

Limpieza de datos

Columnas inútiles. Tenemos una columna id que no necesitamos para nada en el entrenamiento.

```
train = train.drop(columns = "id")
val = val.drop(columns = "id")
```

Datos sin sentido. Son datos médicos, así que no controlo qué datos pueden tener o no sentido (más allá de los evidentes, como `age`).

```
train.describe()
```

	age	height(cm)	weight(kg)	waist(cm)	eyesight(left)	eyesight(right)	hearing(left)	hearing(right)	systo
count	135367.000000	135367.000000	135367.000000	135367.000000	135367.000000	135367.000000	135367.000000	135367.000000	135367.000
mean	44.297214	165.267200	67.152105	83.004576	1.005707	1.001044	1.024097	1.023529	122.511
std	11.840802	8.816742	12.594423	8.968346	0.399835	0.391239	0.153352	0.151576	12.731
min	20.000000	135.000000	30.000000	51.000000	0.100000	0.100000	1.000000	1.000000	77.000
25%	40.000000	160.000000	60.000000	77.000000	0.800000	0.800000	1.000000	1.000000	114.000
50%	40.000000	165.000000	65.000000	83.000000	1.000000	1.000000	1.000000	1.000000	121.000
75%	55.000000	170.000000	75.000000	89.000000	1.200000	1.200000	1.000000	1.000000	130.000
max	85.000000	190.000000	130.000000	127.000000	9.900000	9.900000	2.000000	2.000000	213.000

8 rows × 23 columns

Valores atípicos. Vamos a ver si tenemos alguno.

```
def outlier_eliminator(df, threshold: float = 0.05):
  s_df = df.describe() # statistical dataframe

  for column in s_df.columns:
    # datos necesarios
    n = s_df.loc["count", column]
    q1 = s_df.loc["25%", column]
    q3 = s_df.loc["75%", column]
    mean = s_df.loc["mean", column] # 50% no es la media, es la mediana
    iqr = (q3 - q1) * 1.5

    # calculos
    _range = [mean - iqr, mean + iqr]
    outliers = df[(df[column] < _range[0]) | (df[column] > _range[1])]

    # outliers
    print(f"Outliers para la columna {column}: {len(outliers)} de {n}. BORRADOS: ", end="")
    if len(outliers) != 0 and len(outliers) / n < threshold:
      print("Sí.")
      df = df[(df[column] > _range[0]) & (df[column] < _range[1])] # fíjate que le doy la vuelta
    else:
      print("No.")

    print("### --- ###")

  return df
```

```
train = outlier_eliminator(train, threshold = 0.025)
```

```
Outliers para la columna age: 7225 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna height(cm): 13873 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna weight(kg): 8932 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna waist(cm): 5750 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna eyesight(left): 6711 de 135367.0. BORRADOS: No.
```

```
### --- ###
Outliers para la columna eyesight(right): 6987 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna hearing(left): 135367 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna hearing(right): 135367 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna systolic: 7439 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna relaxation: 5392 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna fasting blood sugar: 13765 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna Cholesterol: 2580 de 135367.0. BORRADOS: Sí.
### --- ###
Outliers para la columna triglyceride: 6026 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna HDL: 5538 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna LDL: 1406 de 135367.0. BORRADOS: Sí.
### --- ###
Outliers para la columna hemoglobin: 3715 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna Urine protein: 131381 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna serum creatinine: 11135 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna AST: 8327 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna ALT: 9135 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna Gtp: 9342 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna dental caries: 131381 de 135367.0. BORRADOS: No.
### --- ###
Outliers para la columna smoking: 0 de 135367.0. BORRADOS: No.
### --- ###
```

Estadísticos básicos. Vamos a ver si existen nulos.

```
train.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 131381 entries, 149220 to 154644
Data columns (total 23 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   age                  131381 non-null  int64
 1   height(cm)           131381 non-null  int64
 2   weight(kg)           131381 non-null  int64
 3   waist(cm)            131381 non-null  float64
 4   eyesight(left)       131381 non-null  float64
 5   eyesight(right)      131381 non-null  float64
 6   hearing(left)        131381 non-null  int64
 7   hearing(right)       131381 non-null  int64
 8   systolic             131381 non-null  int64
 9   relaxation           131381 non-null  int64
 10  fasting blood sugar  131381 non-null  int64
 11  Cholesterol          131381 non-null  int64
 12  triglyceride         131381 non-null  int64
 13  HDL                  131381 non-null  int64
 14  LDL                  131381 non-null  int64
 15  hemoglobin           131381 non-null  float64
 16  Urine protein        131381 non-null  int64
 17  serum creatinine     131381 non-null  float64
 18  AST                  131381 non-null  int64
 19  ALT                  131381 non-null  int64
 20  Gtp                  131381 non-null  int64
 21  dental caries        131381 non-null  int64
 22  smoking              131381 non-null  int64
dtypes: float64(5), int64(18)
memory usage: 24.1 MB
```

Parece que no vamos a tener que preocuparnos de esto.

Correlación. ¿Habrá columnas correladas?

```
corr = train.corr()
for column in corr:
  for index in corr.index:
    corr_v = abs(corr.loc[index, column])
    if corr_v > 0.8 and not corr_v == 1.0:
      print(f"Valor correlado en {index} - {column}, valor: {corr.loc[index, column]}")
```

```
Valor correlado en waist(cm) - weight(kg), valor: 0.8318937180691987
Valor correlado en weight(kg) - waist(cm), valor: 0.8318937180691987
Valor correlado en LDL - Cholesterol, valor: 0.8615422439306766
Valor correlado en Cholesterol - LDL, valor: 0.8615422439306766
```

Eliminamos una de las parejas correladas.

```
train = train.drop(columns = ["waist(cm)", "Cholesterol"])
val = val.drop(columns = ["waist(cm)", "Cholesterol"])
train_val = train_val.drop(columns = ["waist(cm)", "Cholesterol"])
```

Variabilidad. Veamos si tenemos problemas de variabilidad.

```
def numerical_variability(df, threshold: float = 0.1):
  numerical_df = df.select_dtypes("number")

  for column in numerical_df.columns:
    serie = numerical_df[column].value_counts()
    _max = serie.iloc[0] # primer elemento (el más grande) ; max es una palabra reservada
    prop = _max / len(df) * 100.0 # proportion
    if prop > threshold * 100.0:
      print(f"Cuidado, la proporción de valores idénticos para la columna {column} es de {prop}%, que supera el threshold establecido.")
```

```
numerical_variability(train)
```

```
Cuidado, la proporción de valores idénticos para la columna age es de 29.582664159962246%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna height(cm) es de 23.629748593784488%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna weight(kg) es de 15.216812172231906%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna eyesight(left) es de 23.52471057458841%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna eyesight(right) es de 23.98596448497119%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna hearing(left) es de 97.61304907102244%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna hearing(right) es de 97.66480693555386%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna relaxation es de 12.733195819791293%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna Urine protein es de 94.67046224339897%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna serum creatinine es de 22.532938552758772%, que supera el threshold establecido
Cuidado, la proporción de valores idénticos para la columna dental caries es de 80.12269658474209%, que supera el threshold establecido.
Cuidado, la proporción de valores idénticos para la columna smoking es de 56.207518590968256%, que supera el threshold establecido.
```

Eliminamos columnas con poca variabilidad.

```
train = train.drop(columns=["hearing(left)", "hearing(right)", "Urine protein"])
val = val.drop(columns=["hearing(left)", "hearing(right)", "Urine protein"])
train_val = train_val.drop(columns=["hearing(left)", "hearing(right)", "Urine protein"])
```

NO voy a estandarizar, porque si lo hago no podré interpretar mis resultados.

Separo los datos en características y etiquetas.

```
X_train, y_train = train.drop(columns = "smoking"), train.smoking
X_val, y_val = val.drop(columns = "smoking"), val.smoking
X_train_val, y_train_val = train_val.drop(columns = "smoking"), train_val.smoking
```

Entrenamiento

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import roc_auc_score, RocCurveDisplay
```

Definimos la función para predecir (hacerlo de forma más sencilla).

```
def evaluate(X_train, y_train, X_test, y_test, model):
  model = model.fit(X_train, y_train)

  # train
  train_pred = model.predict(X_train)
  train_score = roc_auc_score(y_train, train_pred)

  # test
  test_pred = model.predict(X_test)
  test_score = roc_auc_score(y_test, test_pred)

  return model, train_score, test_score, train_pred, test_pred
```

Predicción de los resultados

Predecimos.

```
model = RandomForestClassifier(random_state=random_seed)
model, train_score, test_score, train_pred, val_pred = evaluate(X_train, y_train, X_val, y_val, model)
```

Aquí tenemos la curva ROC del modelo.

```
RocCurveDisplay.from_predictions(y_val, val_pred);
```

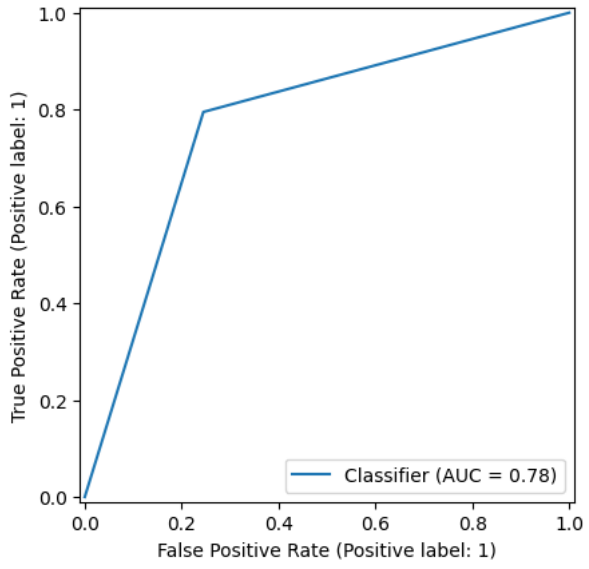

(No vamos a meternos a optimizar el modelo).

Entrenamiento del modelo de caja blanca

Ahora, realizamos la técnica de `model distillation`: entrenamos un modelo de caja blanca con los resultados del modelo de caja negra.

```
from sklearn.tree import DecisionTreeClassifier

interp = DecisionTreeClassifier(max_depth = 3, random_state = random_seed)
```

Fíjate cómo se usan los mismos datos de entreda, pero las predicciones del modelo de caja negra (estamos usando su conocimiento).

```
interp = interp.fit(X_train, train_pred)
```

Interpretación

Para realizar la interpretación, podemos usar la función `plot_tree`.

```
train
```

	age	height(cm)	weight(kg)	eyesight(left)	eyesight(right)	systolic	relaxation	fasting blood sugar	triglyceride	HDL	LDL	hemoglobin	cre
149220	60	170	80	0.9	0.7	124	83	127	102	72	119	15.5	
81952	75	140	50	0.5	0.7	145	67	120	199	42	107	13.1	
39080	45	170	70	1.0	1.2	138	88	85	145	35	124	15.8	
144444	50	165	70	1.0	1.2	132	94	97	257	48	120	14.8	
32600	50	155	65	0.9	1.0	100	60	150	271	48	78	11.7	
...	...	...	...	...	...	...	...	...	...	...	...	...	
75971	40	160	65	1.2	1.2	138	80	89	92	89	99	13.5	
158921	50	170	60	0.3	0.4	125	80	99	211	61	84	16.2	
131650	30	180	105	0.9	0.7	126	84	78	85	38	137	15.5	
104152	35	170	70	1.5	1.5	130	85	92	73	49	115	15.6	
154644	75	160	65	1.0	1.0	139	72	113	65	44	131	14.5	

```
from sklearn.tree import plot_tree

fig = plt.figure(figsize = (20, 25)) # puedes modificar esto según el tamaño del árbol
plot_tree(interp, feature_names = X_train.columns, class_names = y_train.unique().astype(str), filled = True);
```

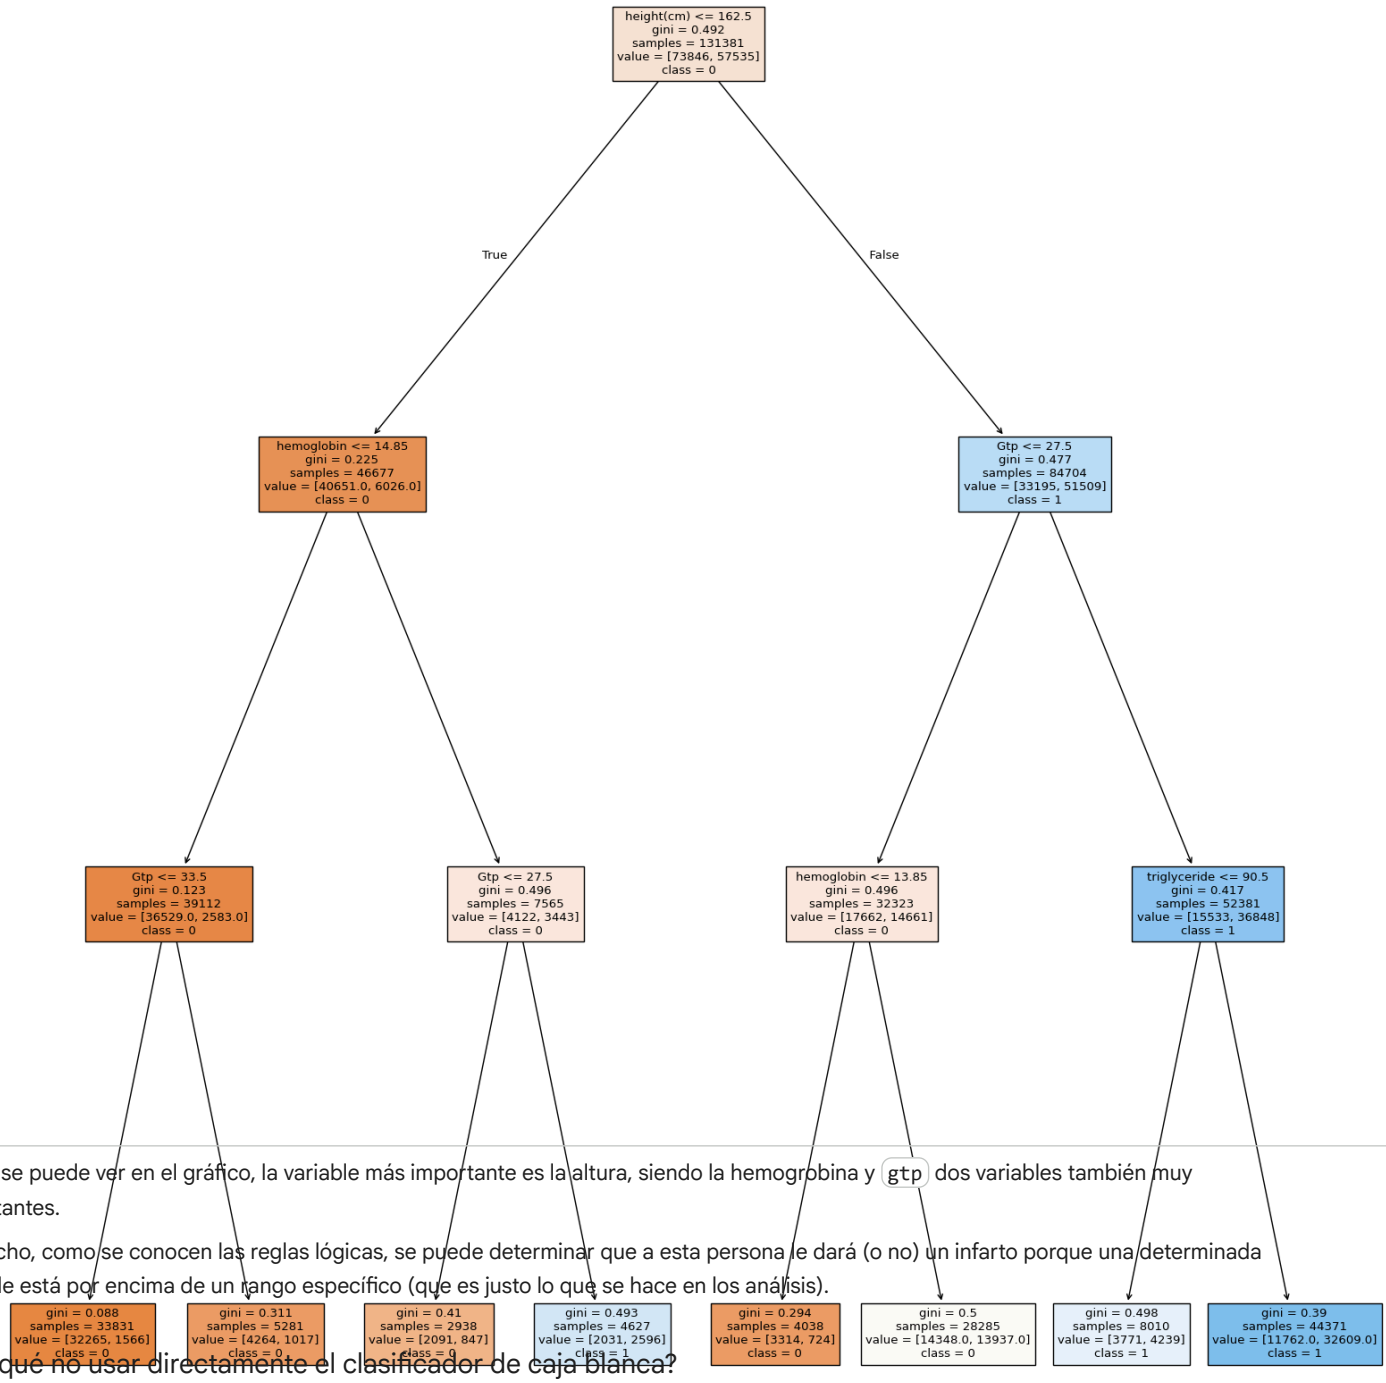

Como se puede ver en el gráfico, la variable más importante es la altura, siendo la hemogrobina y `gtp` dos variables también muy importantes.

De hecho, como se conocen las reglas lógicas, se puede determinar que a esta persona le dará (o no) un infarto porque una determinada variable está por encima de un rango específico (que es justo lo que se hace en los análisis).

¿Por qué no usar directamente el clasificador de caja blanca?

Esta pregunta te la tienes que hacer siempre que vayas a realizar interpretabilidad sobre un modelo: **quizá el modelo interpretable es suficiente para dar solución al problema**.

Podemos comprobarlo.

```
other_model = DecisionTreeClassifier(random_state = random_seed)
other_model, train_score, test_score, train_pred, val_pred = evaluate(X_train, y_train, X_val, y_val, other_model)
```

```
RocCurveDisplay.from_predictions(y_val, val_pred);
```

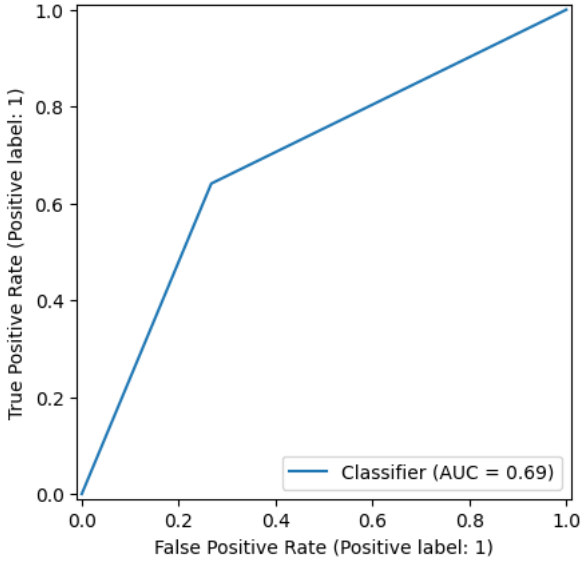
1.0
0.8
0.6
0.4
0.2
0.0
True Positive Rate (Positive label: 1)
0.0
0.2
0.4
0.6
0.8
1.0
False Positive Rate (Positive label: 1)
Classifier (AUC = 0.69)